Relatório do trabalho prático Integração de Sistemas de Informação

Leonel Diogo Ribeiro Freitas

Nº 31520

Github : https://github.com/Leonel-Freitas64/Projeto_ISI

Ano letivo 2026/2027

Escola Superior de Tecnologia

Instituto Politécnico do Cávado e do Ave

Índice

1. Enquadramento 5
   1.1. Contexto e motivação 5
   1.2. Conceitos relevantes 5
2. Problema e objetivos 6
   2.1. Problemas a resolver 6
   2.2. Objetivos 6
3. Estratégia e arquitetura da solução 7
   3.1. Componentes e responsabilidades 7
   3.2. Opções tecnológicas 7
4. Transformações e implementação ETL 8
   4.1. Fase E – Extração e preparação das fontes 8
   4.2. Fase T – Limpeza, cálculos e normalização 8
   4.3. Agrupamento e junção com o INE 9
   4.4. Integração exploratória com API REST 9
5. Execução, persistência e logs 11
   5.1. Fase L – Destinos e exportações 11
   5.2. Logs de processamento 11
   5.3. Orquestração e controlo de execução 12
6. Dashboard Node-RED 13
   6.1. Fluxo de consola 13
   6.2. Indicadores e gráficos 13
7. Análise e discussão dos resultados 15
   7.1. Evolução das contagens 15
   7.2. Exemplo de interpretação estatística 15
   7.3. Limitações e validade 16
8. Demonstração e repositório 17
   8.1. Vídeo e código QR 17
   8.2. Repositório Git 17
9. Conclusão e trabalhos futuros 18

Índice de figuras

Figura 1 - Arquitetura lógica da solução. Esquema elaborado a partir dos ficheiros do projeto. 7
Figura 2 - Fluxo de extração e limpeza 8
Figura 3 - Etapas principais da transformação e junção geográfica no KNIME; contagens da cache da versão analisada 9
Figura 4 - Esquema da exploração complementar da API REST e da análise de correspondências. 10
Figura 5 - Logs no MySQL 11

1. Enquadramento

1.1. Contexto e motivação

A análise de informação imobiliária exige frequentemente a integração de fontes produzidas com finalidades e estruturas distintas. Os anúncios descrevem os preços pedidos, a área e outras características dos imóveis; por outro lado, as estatísticas oficiais disponibilizam indicadores calculados segundo metodologias próprias. Quando se pretende observar a realidade por concelho, é necessário harmonizar identificadores geográficos, formatos, tipos de dados e unidades de medida.

O presente trabalho foi desenvolvido no âmbito da unidade curricular de Integração de Sistemas de Informação, da Licenciatura em Engenharia de Sistemas Informáticos, no ano letivo 2026/2027. O projeto privilegia a experimentação de ferramentas e operadores associados à integração de dados, tal como proposto no enunciado do Trabalho Prático I.

1.2. Conceitos relevantes

Uma arquitetura ETL organiza a extração de dados de origens heterogéneas, a sua transformação para aplicação de regras de qualidade e de negócio e, por fim, o carregamento em destinos que permitam a sua reutilização. Entre as operações típicas encontram-se conversões de tipos, agregações, filtros, junções e mecanismos de rastreabilidade.

O KNIME representa estas operações através de nós ligados num workflow visual. O MySQL é utilizado para persistência relacional, enquanto o Node-RED assegura a consulta e visualização dos indicadores. A normalização de textos mediante expressões regulares reforça a consistência dos atributos usados para estabelecer correspondências entre as fontes.

2. Problema e objetivos

2.1. Problemas a resolver

O problema consiste em transformar dados imobiliários dispersos, incluindo anúncios em CSV e observações estatísticas em JSON, num conjunto de indicadores agregados por concelho e consultáveis numa interface gráfica. Não basta ler dois ficheiros: é necessário eliminar dados inválidos ou redundantes, calcular medidas comparáveis quanto à unidade, normalizar chaves territoriais e guardar resultados num sistema de destino.

2.2. Objetivos

- Implementar as três fases ETL — extração, transformação e carregamento através do KNIME.
- Efetuar limpeza, validação, filtragem, conversão de tipos, remoção de duplicados e normalização textual com Regex.
- Calcular indicadores por concelho e associá-los a um indicador estatístico do INE, preservando a distinção entre preços pedidos e valores de vendas.
- Persistir dados em MySQL, exportar dados para JSON/XML e produzir logs de contagem de registos por etapa.
- Criar um dashboard em Node-RED com seleção de concelhos e indicadores gráficos.
- Experimentar uma API REST como fonte complementar e avaliar a cobertura da junção efetuada com os dados do INE.

3. Estratégia e arquitetura da solução

3.1. Componentes e responsabilidades

A solução utiliza KNIME como motor de processamento ETL, MySQL como destino relacional e Node-RED como camada de exploração visual. O fluxo principal cruza anúncios imobiliários com um ficheiro estatístico do INE. Em paralelo, uma ramificação utiliza a API Estates Portugal para testar correspondências, sem alterar os indicadores que alimentam o dashboard.

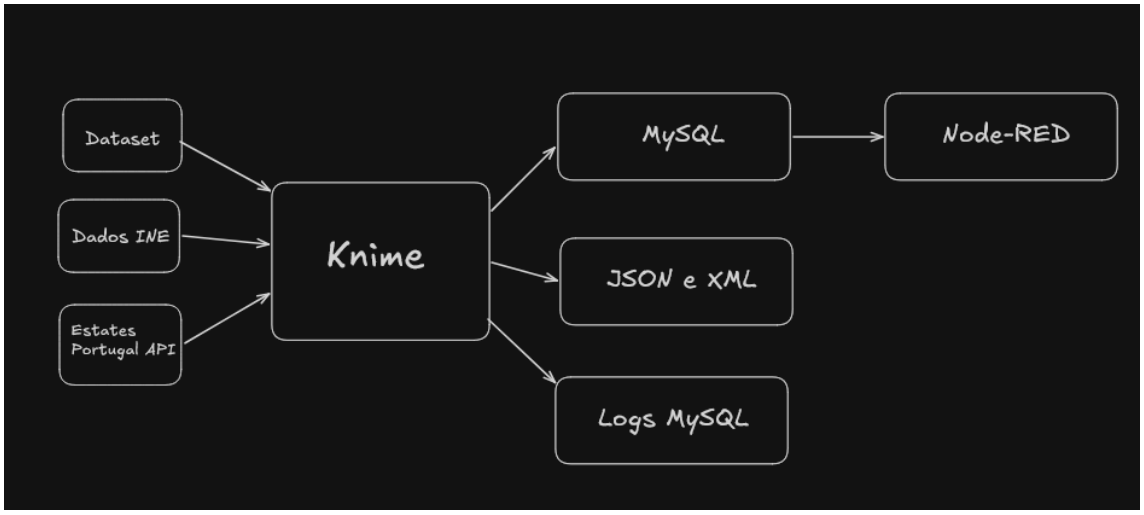


Figura 1 - Arquitetura lógica da solução. Esquema elaborado a partir dos ficheiros do projeto.

Componente	Papel no sistema
CSV imobiliário	Fonte de anúncios com preço, área, concelho e ano de construção.
JSON do INE	Fonte de observações estatísticas por geografia.
API REST	Consulta complementar de observações da série 0012234.
KNIME	Aplicação de transformações, agregações, junções e exportações.
MySQL	Persistência de resultados analíticos e logs ETL.
Node-RED	Consulta SQL e visualização dinâmica por concelho.

3.2. Opções tecnológicas

A adoção do KNIME permite construir e inspecionar cada transformação de forma visual, tornando observáveis as tabelas intermédias. A escolha de MySQL separa o tratamento dos dados da sua consulta e suporta a integração posterior com Node-RED. A API REST é deliberadamente mantida numa ramificação auxiliar, dado que a cobertura das correspondências ainda é limitada nos resultados observados.

4. Transformações e implementação ETL

4.1. Fase E – Extração e preparação das fontes

O ramo principal inicia-se no CSV Reader, cuja saída em cache contém 187 764 linhas e 23 colunas. Seguem-se operações de seleção de atributos e de filtragem. Os dados estatísticos são lidos através do JSON Reader, processados por nós JSON Path e Ungroup, e sujeitos a seleção e conversão de campos.
A coexistência de CSV, JSON e respostas HTTP permite demonstrar a importação de fontes heterogéneas. A API REST é consumida pelo nó GET Request num ramo independente. A correspondência e o período das observações estatísticas devem ser confirmados ao interpretar qualquer comparação

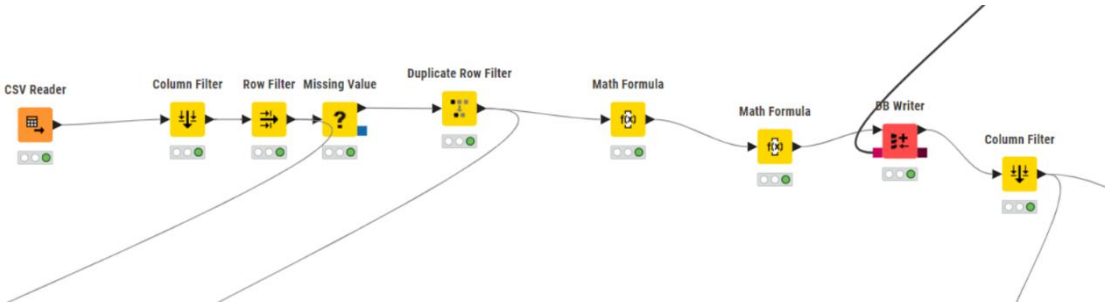


Figura 2 - Fluxo de extração e limpeza

4.2. Fase T – Limpeza, cálculos e normalização

No ramo imobiliário são usados Missing Value, Row Filter e Duplicate Row Filter. A configuração do filtro de anúncios observada no projeto estabelece preço superior a 50 000 €, inferior a 800 000 € e área total inferior a 1 000 m^2. O Math Formula calcula o preço pedido por metro quadrado, e a idade do imóvel é obtida por diferença entre 2026 e o ano de construção. A idade depende, portanto, do ano de referência fixado na expressão:

```
price_per_m2 = round(Price / TotalArea, 2)
Age_of_Property = 2026 - ConstructionYear
```

A aplicação de expressões regulares reforça a qualidade das chaves geográficas. Nos nós String Manipulation (Multi Column), a expressão seguinte substitui sequências de espaços em branco por um espaço e remove espaços no início e no fim. A operação é aplicada, em cada ramo, às colunas selecionadas na configuração do nó.

```
strip(regexReplace($$CURRENTCOLUMN$$, "\\s+", " "))
```

Esta normalização procura reduzir diferenças meramente tipográficas entre os nomes dos concelhos. Não corrige automaticamente variantes de acentuação, designações alternativas ou diferenças no nível territorial; por isso, as correspondências devem continuar a ser verificadas.

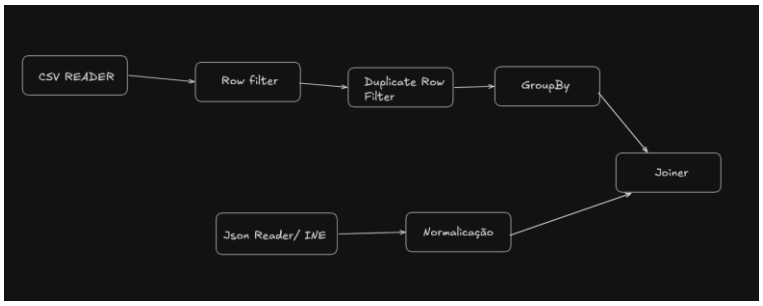


Figura 3 - Etapas principais da transformação e junção geográfica no KNIME; contagens da cache da versão analisada

4.3. Agrupamento e junção com o INE

Depois da preparação dos anúncios, o GroupBy calcula, por concelho, o preço médio anunciado, a média do preço por metro quadrado, a idade média e o número de anúncios. A junção principal é realizada pelo Joiner, relacionando os nomes geográficos dos anúncios com a designação geográfica proveniente do INE. A configuração observada corresponde a uma junção que mantém na saída principal apenas os registos com correspondência.

O workflow tem ainda duas fórmulas de comparação: a diferença absoluta entre o indicador estatístico e a média anunciada por metro quadrado, e uma diferença percentual com a média anunciada como denominador. As fórmulas guardadas utilizam floor(), pelo que os valores calculados são arredondados por defeito para inteiros. Esta decisão deve ser distinguida da apresentação de percentagens decimais num exemplo descritivo.

```
diferença_absoluta = floor(valor_INE - média_anunciada_m2)
diferença_percentual = floor(((valor_INE - média_anunciada_m2) / média_anunciada_m2) * 100)
```

4.4. Integração exploratória com API REST

Foi acrescentado um ramo que consome o endpoint https://api.estatesportugal.com/api/v1/catalog/series/0012234/observations/ por meio de GET Request. A resposta é preparada com JSON Path, Ungroup, seleção de colunas e filtragem. O Joiner testa a correspondência entre as observações da API e os dados previamente extraídos do INE.

Nos resultados em cache da versão analisada, foram extraídos 1 000 elementos na fase de expansão da API, 137 observações permaneceram após filtragem e a saída principal do Joiner auxiliar contém 37 linhas. Esta contagem representa linhas resultantes da junção, não necessariamente 37 concelhos distintos. Dada a cobertura limitada, o ramo foi usado como exploração complementar e não como substituição da fonte estatística principal.

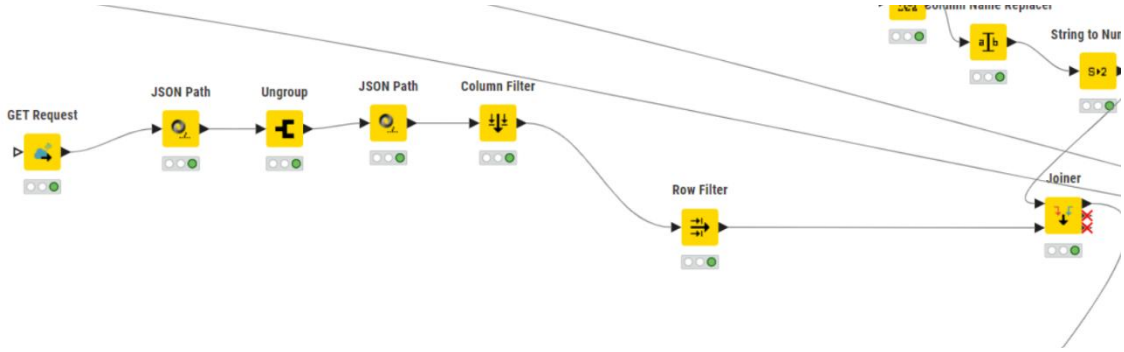


Figura 4 - Esquema da exploração complementar da API REST e da análise de correspondências.

5. Execução, persistência e logs

5.1. Fase L – Destinos e exportações

Os nós DB Writer permitem persistir resultados no MySQL. A tabela análise imobiliária constitui a fonte consultada pelo Node-RED. Existe também uma tabela para dados imobiliários preparados. Na configuração do ficheiro KNIME analisado, o DB Writer da tabela analítica estava configurado, mas não executado após as alterações mais recentes, pelo que a atualização efetiva dessa tabela deve ser demonstrada numa execução final.

Os dados de anúncios preparados seguem também para Table to JSON, JSON Writer, JSON to XML e XML Writer. É importante distinguir este ramo de exportação dos dados analíticos finais: o JSON e o XML enviados para análise contêm atributos de anúncios individuais — Price, City, price_per_m2 e Age_of_Property — e não os indicadores resultantes do Joiner com o INE. Os dois ficheiros enviados foram produzidos com versões diferentes do dataset, pelo que as contagens não devem ser comparadas como se fossem duas serializações da mesma execução.

	total_registos	etapa
▶	118904	Row filter dos dados
	103259	Filtrar Dados Relevantes
	37	Integração Api e JSON
	151	integracao INE

Figura 5 - Logs no MySQL

5.2. Logs de processamento

Para acompanhar o número de linhas nas etapas principais, foram introduzidas ramificações com Extract Table Dimension, seleção da informação relevante, renomeação e identificação da etapa. Os registos são reunidos por concatenação, de forma a produzir uma tabela com uma linha por ponto de controlo. Segundo a implementação posteriormente confirmada pelo autor, estes registos são persistidos numa tabela MySQL dedicada, logs_etl.

A estrutura de registo prevista contém o nome da etapa, a respetiva contagem de linhas e um momento de inserção atribuído pela base de dados. A possibilidade de consultar registos de diferentes execuções facilita a análise de alterações inesperadas na filtragem ou na junção. Este mecanismo regista métricas de volume; não deve ser confundido com captura automática de exceções de execução.

```
SELECT etapa, total_registos, data_execucao
FROM listings.logs_etl
ORDER BY data_execucao DESC, id DESC;
```

5.3. Orquestração e controlo de execução

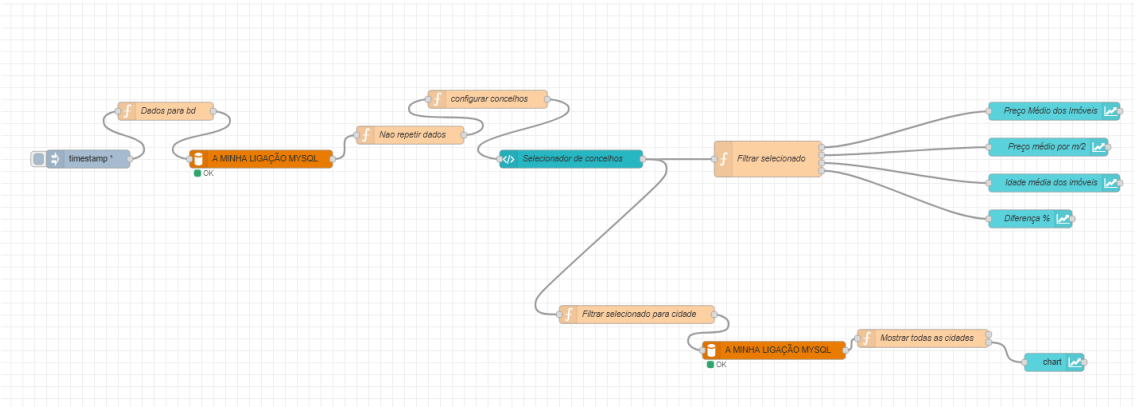
As dependências entre os nós do KNIME estabelecem a ordem de processamento de cada ramo. A solução não inclui, na versão disponibilizada, um Job autónomo com agendamento ou tratamento completo de falhas por Try/Catch. O registo de logs funciona como mecanismo de observabilidade das saídas dos principais operadores, enquanto a integração com o Node-RED permite consumir os resultados já persistidos. Assim, a orquestração implementada corresponde ao encadeamento explícito das transformações no workflow.

6. Dashboard Node-RED

6.1. Fluxo de consola

O fluxo Node-RED exportado consulta a tabela analise_imobiliaria com a instrução SELECT * FROM analise_imobiliaria;

Os resultados são guardados em contexto de fluxo (imobRows), de modo a permitir filtragens posteriores por concelho sem repetir imediatamente a consulta SQL. A seleção é disponibilizada através de um ui-template com caixa de pesquisa, seleção múltipla e botão para aplicar filtros.



6.2. Indicadores e gráficos

A função de filtragem transforma os dados selecionados em pares de propriedades city e value, destinados a quatro nós ui-chart. Todos os gráficos são de barras e utilizam a categoria geográfica no eixo horizontal. A interface utiliza o pacote @flowfuse/node-red-dashboard, identificado na configuração exportada como versão 1.33.0.

Visualização	Atributo de origem	Interpretação
Preço médio	mean_price / Mean(Price)	Preço médio pedido dos anúncios do concelho.
Preço por m^2	mean_price_per_m2 / Mean(price_per_m2)	Média do preço pedido por metro quadrado.
Idade média	mean_age_of_property / Mean(Age_of_Property)	Média das idades estimadas dos imóveis.
Diferença percentual	difference_percent	Diferença percentual face ao indicador do INE; dependente da fórmula usada.

A exportação JSON comprova a configuração e as ligações do fluxo, mas uma captura do dashboard em funcionamento continua a ser a evidência visual mais

adequada para a apresentação. Os valores apresentados devem ser verificados após a atualização da tabela MySQL.

7. Análise e discussão dos resultados

7.1. Evolução das contagens

A Tabela 3 apresenta contagens registadas na cache da versão KNIME analisada. Estes valores ilustram a redução progressiva do volume de dados e permitem identificar os pontos de maior impacto do processo. A reexecução final deve permitir confrontar estas contagens com os logs persistidos em MySQL.

Etapa KNIME	Linhas observadas	Leitura do resultado
CSV Reader	187 764	Registos recebidos da fonte imobiliária.
Row Filter	118 904	Registos que satisfazem os limites estabelecidos.
Duplicate Row Filter	103 259	Registos após remoção de duplicados.
GroupBy	275	Grupos agregados por concelho.
Row Filter INE	198	Observações estatísticas mantidas nesse ramo.
Joiner principal	151	Linhas integradas na junção principal.
Row Filter API	137	Observações selecionadas da API.
Joiner auxiliar	37	Linhas de correspondência API–INE.

A filtragem inicial remove 68 860 linhas, aproximadamente 36,7% do volume de entrada. A remoção de duplicados retira outras 15 645 linhas, correspondentes a cerca de 13,2% dos registos que chegaram a essa operação. No total, os anúncios passam de 187 764 para 103 259 linhas, uma redução de cerca de 45,0%.

Os 275 grupos resultantes do GroupBy contrastam com as 151 linhas da saída principal do Joiner. É necessário inspecionar as correspondências não encontradas para atribuir causas a esta diferença: as expressões regulares eliminam inconsistências de espaços, mas não resolvem, por si só, designações geográficas distintas ou períodos de referência divergentes.

7.2. Exemplo de interpretação estatística

Um registo apresentado no desenvolvimento para Abrantes indicava preço médio anunciado de 163 591 €, preço anunciado médio de 1 274 €/m^2, idade média de 47 anos, 384 anúncios e indicador do INE de 1 513 €/m^2. A diferença simples é de 239 €/m^2 e a diferença percentual não arredondada, tomando 1 274 €/m^2 como base, é de aproximadamente 18,8%. Se for aplicada a função floor() da fórmula KNIME, o resultado devolvido é 18%. Estes dados são ilustrativos e devem ser confirmados na tabela analítica atualizada.

O valor do INE corresponde a uma mediana de vendas efetuadas, enquanto a média dos anúncios se refere a preços pedidos. A comparação é descritiva e não permite

concluir, isoladamente, que os imóveis estejam subavaliados ou sobreavaliados. É necessário considerar diferenças de período, tipologia, amostra e método estatístico.

7.3. Limitações e validade

A origem pública, a licença e a data de recolha do CSV imobiliário não estão explicitadas nos ficheiros analisados; devem ser documentadas.

Os resultados quantitativos retirados de cache não substituem a execução completa e repetível do workflow.

O Joiner principal depende da compatibilidade das chaves geográficas, que pode ir além da normalização de espaços.

O ramo REST apresenta correspondência limitada e não foi integrado no cálculo principal dos indicadores.

Há caminhos absolutos de ficheiros locais e uma configuração de exportação XML que pode falhar se o ficheiro de destino já existir.

8. Demonstração e repositório

8.1. Vídeo e código QR

A demonstração deverá apresentar a leitura de fontes heterogéneas, a aplicação de Regex, as principais transformações no KNIME, a junção com o INE, a consulta à API REST, a persistência MySQL, os logs e a utilização do dashboard Node-RED. O enunciado solicita a disponibilização do vídeo por meio de um código QR.

8.2. Repositório Git

O repositório deverá reunir o workflow KNIME, a exportação do fluxo Node-RED, os scripts SQL de criação de tabelas, a documentação e, quando os direitos de reutilização o permitirem, amostras ou instruções para obter os datasets. Deve incluir orientações de instalação, execução e configuração das ligações locais, sem publicar credenciais.

Repositório Git: https://github.com/Leonel-Freitas64/Projeto_ISI

9. Conclusão e trabalhos futuros

Foi desenvolvido um protótipo de integração de dados imobiliários que articula KNIME, MySQL e Node-RED. O fluxo principal realiza leitura de fontes heterogéneas, filtragem, tratamento de valores em falta, remoção de duplicados, transformação numérica, normalização textual com expressões regulares, agregação geográfica, junção com informação estatística e armazenamento relacional. A disponibilização de resultados num dashboard permite explorar indicadores por concelho.

As extensões introduzidas reforçam os critérios de mais-valia da unidade curricular: foi experimentado o acesso a uma API REST, foram aplicadas expressões regulares às chaves textuais e foram construídos logs de contagens armazenados em MySQL. As exportações JSON e XML demonstram mecanismos de serialização de dados preparados. A solução não apresenta um Job agendado autónomo nem uma equivalência estatística entre preços anunciados e valores de vendas, limitações que importa reconhecer.

Como desenvolvimentos futuros propõe-se validar a execução integral após a última alteração, aprofundar o tratamento de designações geográficas não correspondidas, parametrizar o ano usado no cálculo de idades, garantir a portabilidade dos caminhos de ficheiros e expandir os logs para registar falhas e duração das execuções. Uma integração REST mais abrangente deverá depender da disponibilidade e compatibilidade efetiva dos dados.

10. Referências bibliográficas

FlowFuse. (s.d.). Chart ui-chart — Node-RED Dashboard 2.0. https://dashboard.flowfuse.com/nodes/widgets/ui-chart.html

Instituto Nacional de Estatística. (s.d.). Indicador 0012234: Valor mediano das vendas de alojamentos familiares nos últimos 12 meses (Metodologia 2022 — €/m^2). Sistema de Metainformação. https://smi.ine.pt/Indicador/Detalhes_TabIndicador/18376?clear=True

KNIME AG. (s.d.). KNIME Analytics Platform Documentation. https://docs.knime.com/

Estates Portugal. (s.d.). API REST — Observações da série 0012234. https://api.estatesportugal.com/api/v1/catalog/series/0012234/observations/